

Checkpoint 5

Statistical Computing with R & Python + Machine Learning & Modelling

Análise estatística e agrupamento K-means no dataset Wine

Integrantes:

Nome	RM
Arthur Costa Donaire	RM571283
Felipe Pereira de Jesus	RM573263
Giovanna Pereira de Oliveira	RM570989
Gustavo Paiva Silva	RM572249
Maria Eduarda Soares Lopes e Souza	RM572612

Este relatório integra a análise estatística descritiva e probabilística de duas variáveis do dataset Wine (**Alcohol** e **Malic.acid**) com um agrupamento não supervisionado por K-means. Alcohol é uma variável homogênea e quase simétrica (coeficiente de variação de 6,24%); Malic.acid é heterogênea e assimétrica à direita (47,82%). A distribuição Normal aproxima razoavelmente Alcohol e é limitada para Malic.acid. O K-means com $k = 3$, escolhido por Elbow e Silhouette, separou três perfis químicos distintos.

Objetivo e dados

O objetivo é integrar análise estatística descritiva e probabilística com modelagem não supervisionada, usando o dataset Wine (Kaggle: harrywang/wine-dataset-for-clustering). O conjunto tem **178 vinhos** e **14 colunas**: a coluna *Wine*, que guarda a classe original (1, 2 ou 3), e 13 medidas químicas quantitativas (Alcohol, Malic.acid, Ash, Acl, Mg, Phenols, Flavanoids, Nonflavanoid.phenols, Proanth, Color.int, Hue, OD e Proline). Não há valores nulos nas variáveis usadas.

A Parte 1 usa Python (pandas, NumPy, SciPy e Matplotlib). A Parte 2 usa scikit-learn. O código completo e reproduzível está no notebook *CP5_TropadeElite_SCWRP_ML_Wines.ipynb*.

1. Statistical Computing with R & Python

Variáveis selecionadas: **Alcohol** (teor alcoólico) e **Malic.acid** (concentração de ácido málico). A escolha foi deliberada: Alcohol tem baixa dispersão relativa e Malic.acid tem dispersão muito maior, o que permite comparar como cada técnica se comporta em uma variável homogênea e em uma heterogênea.

1.1 - (a) Visualização dos dados: distribuição de frequências

Alcohol

Intervalo	Frequência	Freq. relativa (%)	Freq. acumulada	Freq. rel. acum. (%)
(11,026 ; 11,452]	3	1,69	3	1,69
(11,452 ; 11,874]	15	8,43	18	10,11
(11,874 ; 12,297]	23	12,92	41	23,03
(12,297 ; 12,719]	28	15,73	69	38,76
(12,719 ; 13,141]	28	15,73	97	54,49
(13,141 ; 13,563]	30	16,85	127	71,35
(13,563 ; 13,986]	29	16,29	156	87,64
(13,986 ; 14,408]	20	11,24	176	98,88
(14,408 ; 14,830]	2	1,12	178	100,00




Figura 1 - Histograma de Alcohol (9 classes), com média e mediana.

Interpretação. As quatro classes centrais (12,30 a 13,99) reúnem 115 dos 178 vinhos (64,6%), enquanto as classes extremas têm apenas 3 e 2 vinhos. A média (13,00) é praticamente igual à mediana (13,05) e o coeficiente de assimetria é próximo de zero (-0,05): a distribuição é aproximadamente simétrica e concentrada.

Malic.acid

Intervalo	Frequência	Freq. relativa (%)	Freq. acumulada	Freq. rel. acum. (%)
(0,735 ; 1,302]	21	11,80	21	11,80
(1,302 ; 1,864]	68	38,20	89	50,00
(1,864 ; 2,427]	25	14,04	114	64,04
(2,427 ; 2,989]	16	8,99	130	73,03
(2,989 ; 3,551]	16	8,99	146	82,02
(3,551 ; 4,113]	17	9,55	163	91,57
(4,113 ; 4,676]	8	4,49	171	96,07
(4,676 ; 5,238]	4	2,25	175	98,31
(5,238 ; 5,800]	3	1,69	178	100,00




Figura 2 - Histograma de Malic.acid (9 classes), com média e mediana.

Interpretação. A classe de 1,30 a 1,86 concentra 68 vinhos (38,2%) e metade da amostra (89 de 178) está abaixo de 1,86; depois a frequência cai lentamente até 5,80. A média (2,34) fica acima da mediana (1,865) e o coeficiente de assimetria é positivo (1,04), o que caracteriza assimetria à direita.

1.2 - (b) Análise descritiva: tendência central, dispersão e quartis

Medida	Alcohol	Malic.acid
Média	13,0006	2,3363
Mediana	13,0500	1,8650
Moda	12,3700	1,7300
Mínimo	11,0300	0,7400
Máximo	14,8300	5,8000

Medida	Alcohol	Malic.acid
Amplitude	3,8000	5,0600
Variância	0,6591	1,2480
Desvio padrão	0,8118	1,1171
Coef. variação (%)	6,2445	47,8159
Q1	12,3625	1,6025
Q2	13,0500	1,8650
Q3	13,6775	3,0825
IQR	1,3150	1,4800




Figura 3 - Boxplots: caixa de Q1 a Q3, traço escuro na mediana.

Tendência central. Em Alcohol, média e mediana praticamente coincidem (13,00 e 13,05). Em Malic.acid, a média (2,34) é maior que a mediana (1,865), efeito de valores altos que puxam a média para cima. A moda é pouco informativa em variáveis contínuas e é apresentada por completude.

Dispersão. O desvio padrão absoluto (0,81 contra 1,12) subestima a diferença entre as variáveis, porque as escalas são distintas. O coeficiente de variação corrige isso: **6,24%** em Alcohol (baixa dispersão relativa) contra **47,82%** em Malic.acid (heterogeneidade muito maior, quase oito vezes).

Quartis. 50% dos vinhos têm Alcohol entre 12,36 e 13,68 (IQR = 1,32) e Malic.acid entre 1,60 e 3,08 (IQR = 1,48). Em Malic.acid a mediana (1,865) está muito próxima de Q1 (1,60) e a caixa se estende para a direita, reforçando a assimetria positiva. Pela regra de Tukey ($Q3 + 1,5 \times IQR = 5,30$), há 3 vinhos de Malic.acid acima do limite (5,51, 5,65, 5,80), enquanto Alcohol não apresenta valores atípicos.

1.3 - (c) Análise probabilística

Foi adotada a **distribuição Normal** como modelo teórico, com a média e o desvio padrão amostrais de cada variável: Alcohol $\sim N(13,00; 0,81)$ e Malic.acid $\sim N(2,34; 1,12)$. As probabilidades vêm da função de distribuição acumulada F: $P(X > a) = 1 - F(a)$ e $P(a < X < b) = F(b) - F(a)$ (função *norm.cdf* do SciPy). Cada valor teórico foi comparado com a frequência empírica, isto é, a proporção real de vinhos no intervalo. Foram feitos quatro cálculos, dois por variável, uma cauda e um intervalo central.

Variável	Cálculo	Prob. Normal (%)	Freq. empírica (%)	Diferença (p.p.)
Alcohol	$P(X > 13,5)$	26,92	30,90	4,0
Alcohol	$P(12,5 < X < 14,0)$	62,21	55,62	6,6
Malic.acid	$P(X > 3,0)$	27,62	26,40	1,2
Malic.acid	$P(1,5 < X < 2,5)$	33,12	46,07	12,9

Tabela - Probabilidades pela Normal e frequências empíricas (p.p. = pontos percentuais, em valor absoluto).




Figura 4 - Histogramas (em densidade) com a curva Normal ajustada.

Interpretação. Em **Alcohol**, a Normal descreve razoavelmente a distribuição: subestima $P(X > 13,5)$ em 4,0 p.p. e superestima o intervalo central $P(12,5 < X < 14,0)$ em 6,6 p.p. Em **Malic.acid**, a cauda $P(X > 3,0)$ fica próxima do observado (diferença de 1,2 p.p.), mas o intervalo central $P(1,5 < X < 2,5)$ é fortemente subestimado: 33,12% pela Normal contra 46,07% nos dados (cerca de 13 p.p.). A causa é a assimetria à direita: os dados se acumulam abaixo de 1,9, enquanto a Normal distribui massa simetricamente em torno da média. Assim, a Normal é uma aproximação aceitável para Alcohol e limitada para Malic.acid; para esta, uma distribuição assimétrica seria mais adequada. Não foi aplicado teste formal de normalidade.

2. Machine Learning & Modelling - K-means

2.1 - Introdução: problema e solução proposta

Problema. Há 178 vinhos descritos por 13 medidas químicas e o objetivo é descobrir quais são mais parecidos entre si, formando grupos com perfis distintos, sem fornecer ao algoritmo a classe original (aprendizado não supervisionado).

Solução proposta. Aplicar o K-means, que forma grupos minimizando a distância dos registros aos centróides, em quatro passos: (1) pré-processamento (remover a classe, tratar nulos e padronizar); (2) escolha do número de grupos k com Elbow e Silhouette; (3) ajuste do K-means final; (4) análise do perfil químico de cada grupo (teor alcoólico, acidez, cinza etc.). A coluna *Wine* foi removida antes do treinamento para evitar que a classe conhecida influencie o agrupamento.

2.2 - Pré-processamento

O dataset possui 178 registros e 13 características numéricas usadas no agrupamento, sem valores nulos. Como as variáveis têm escalas muito diferentes (por exemplo, Proline na casa dos milhares e Hue em torno de 1), todas foram padronizadas com *StandardScaler* (média 0 e desvio padrão 1), já que o K-means é sensível à escala. As outras 12 variáveis químicas foram mantidas, pois todas descrevem o perfil do vinho e nenhuma é identificador ou rótulo; como não há valores nulos, não foi necessária imputação.

2.3 - Escolha do número de clusters: Elbow e Silhouette

Foram testados valores de k entre 2 e 8 ($random_state = 42$ e $n_init = 10$). O Elbow avalia a redução da inércia; o Silhouette mede a coesão e a separação dos grupos.

k	Inércia	Silhouette
2	1658,76	0,2593
3	1277,93	0,2849
4	1175,43	0,2602
5	1109,51	0,2016
6	1046,00	0,2372
7	981,60	0,2036
8	935,20	0,1570




Figura 5 - Método Elbow e Silhouette Score para k de 2 a 8 (k = 3 marcado).

O maior Silhouette (**0,2849**) ocorre em **k = 3**, e o Elbow mostra queda forte da inércia até a região de três grupos (de 1658,76 em k = 2 para 1277,93 em k = 3, contra quedas menores depois). Por isso, adotou-se k = 3. O valor do Silhouette é modesto, o que indica grupos com alguma sobreposição.

2.4 - Ajuste final e perfil dos clusters

Cluster	n	Alcohol	Malic.acid	Ash	Phenols	Flavanoids	Color.int	Hue	Proline
0	65	12,25	1,90	2,23	2,25	2,05	2,97	1,06	510,17
1	51	13,13	3,31	2,42	1,68	0,82	7,23	0,69	619,06
2	62	13,68	2,00	2,47	2,85	3,00	5,45	1,07	1100,23

Tabela - Médias por cluster (variáveis na escala original).




Figura 6 - Clusters no plano Alcohol x Malic.acid.

Análise dos grupos (item e)

Qual o teor alcoólico dos vinhos de cada grupo? Cluster 0: **12,25** (o menor); Cluster 1: **13,13** (intermediário); Cluster 2: **13,68** (o maior).

Qual o grupo com vinhos mais ácidos? O **Cluster 1**, com Malic.acid médio de **3,31**, contra 1,90 (Cluster 0) e 2,00 (Cluster 2). O ácido málico é usado como referência de acidez, já que o dataset não traz pH.

O que diferencia um grupo do outro?

- **Cluster 0 (65 vinhos), perfil leve:** menor teor alcoólico (12,25), cor mais clara (Color.int 2,97), menor Proline (510) e menor cinza (Ash 2,23).
- **Cluster 1 (51 vinhos), perfil ácido e colorido:** mais ácido (3,31), cor mais intensa (7,23), Hue mais baixo (0,69), menos fenóis (1,68) e menos flavonoides (0,82), com álcool intermediário (13,13).
- **Cluster 2 (62 vinhos), perfil alcoólico e encorpado:** maior teor alcoólico (13,68), Proline muito mais alto (1100), mais fenóis (2,85) e flavonoides (3,00), maior cinza (2,47) e acidez baixa (2,00).

A cinza (Ash) separa pouco os grupos (2,23 a 2,47); Proline, intensidade de cor e flavonoides diferenciam muito mais. No gráfico Alcohol x Malic.acid há sobreposição entre os grupos, o que é esperado: o agrupamento usa as 13 variáveis, e não apenas essas duas.

3. Conclusão

A Parte 1 mostrou que Alcohol é homogêneo e aproximadamente simétrico, enquanto Malic.acid é mais disperso e assimétrico à direita; a distribuição Normal aproxima bem a primeira e de forma limitada a segunda. A Parte 2 demonstrou a importância da padronização para o K-means e usou dois critérios complementares, Elbow e Silhouette, para definir três grupos. A solução com três clusters separou perfis de vinho com diferenças claras em álcool, ácido málico, cor, compostos fenólicos e Proline.

Limitações e próximos passos

Entre as limitações estão o Silhouette moderado, a ausência de teste formal de normalidade e o uso de apenas duas variáveis na análise estatística. Como próximos passos, sugerem-se testes de normalidade, distribuições assimétricas para Malic.acid e a comparação dos clusters com a classe original (coluna *Wine*) para validar o agrupamento.

Referências

Dataset: Kaggle - Wine Dataset for Clustering (harrywang), <https://www.kaggle.com/datasets/harrywang/wine-dataset-for-clustering>. Bibliotecas: pandas, NumPy, SciPy, scikit-learn e Matplotlib.